

TITANIC SURVIVAL PREDICTION

Iago Barroso Ortega, Alai Miranda Blanco Lascurain,
Catalina Fullana Mora, Rubén Matey Martín



Introducción y motivación

- Objetivo : estudiar el conjunto de datos de características de los supervivientes del Titanic con el objetivo de predecir quién sobrevivió al hundimiento
- Se divide en dos fases: preprocesamiento de los datos y el entrenamiento y optimización de los agentes
- Nuestra motivación, más allá de estudiar los sesgos humanos durante la evacuación, ha sido comprobar como los modelos son capaces de aprender y replicar estos sesgos humanos solamente con los datos



Análisis exploratorio y preprocesado de datos

El conjunto de datos contiene información sobre pasajeros del Titanic, incluyendo:

- PassengerId: identificador del pasajero
- Survived: variable objetivo (0 = no, 1 = sí)
- Pclass: clase del billete (1ª, 2ª, 3ª)
- Name: nombre del pasajero
- Sex: sexo
- Age: edad (con valores faltantes)
- SibSp: número de hermanos/cónyuges a bordo
- Parch: número de padres/hijos a bordo
- Ticket: número de ticket
- Fare: tarifa pagada
- Cabin: cabina (muchos valores nulos)
- Embarked: puerto de embarque (algún valor nulo)

Técnicas de preprocesado seguidas:

- Para los nulos:
 - Mediana: Age y Fare
 - Moda: Embarked
 - Eliminamos cabin por tener demasiados nulos
- Eliminamos las variables PassengerId, Name, Ticket y Cabin
- Convertimos en categorías numéricas Sex y Embarked



Modelo KNN

	Valores de predicción	
Valores reales	103 Verdaderos Negativos	7 Falsos Positivos
	23 Falsos Negativos	45 Verdaderos Positivos

- Accuracy conseguida: 0.831



Modelo Árbol de decisiones

	Valores de predicción	
Valores reales	99 Verdaderos Negativos	11 Falsos Positivos
	23 Falsos negativos	45 Verdaderos Positivos

Variables más influyentes:

- Género: 0.69
- 1ª/2ª/3ª clase: 0.17
- Age: 0.08

- Accuracy conseguida: 0.809
- Sesgo “conservador”



Modelo Red Neuronal

	Valores de predicción	
Valores reales	103 Verdaderos Negativos	7 Falsos Positivos
	21 Falsos negativos	47 Verdaderos Positivos


- Accuracy conseguida: 0.843
- Sesgo “conservador”
- Una sola capa oculta con 10 neuronas



Modelo Support Vector Machine

	Valores de predicción	
Valores reales	105 Verdaderos Negativos	5 Falsos Positivos
	26 Falsos Negativos	42 Verdaderos Positivos

- Accuracy conseguida: 0.826
- Sesgo conservador
- 0.945 de precisión al predecir no supervivientes
- 0.880 de precisión al predecir supervivientes
- Hiperparámetros utilizados: kernel en poly, tolerancia error (C) = 1.0, alcance(gamma) en auto



Conclusión

Para este problema de predicción del Titanic, donde el dataset no tiene un gran número de registros (900) y las columnas son relativamente pocas y están bien definidas, la Red Neuronal ofrece el mejor rendimiento global en cuanto a la predicción.

Si la prioridad fuese interpretar el modelo, el Árbol de Decisiones, con sus campos de Sex_male y Pclass más influyentes, sería la elección. Pero si el objetivo es maximizar la capacidad predictiva, la red neuronal gana.

